

Cybersecurity Threat Severity and Impact Classification

Luis Carlos Vanegas Zapata¹, Alejandra Cano Espinosa², Robinson Dario Henao Botero³ Departamento de Ingeniería de Sistemas

Universidad de Antioquia, Colombia

Proyecto de Aula — Modelos y Simulación de Sistemas II

{lcarlos.vanegas, alejandra.canoel, robinson.henao}@udea.edu.co

Resumen—Este documento presenta el Entregable I del proyecto de aula del curso Modelos y Simulación de Sistemas II, correspondiente a la descripción del problema y la revisión del estado del arte para el desarrollo de un sistema de clasificación de la severidad e impacto de amenazas de ciberseguridad, basado en técnicas de aprendizaje de máquina (Machine Learning, ML). Se emplea la base de datos pública *Global Cybersecurity Threats (2015–2024)*, disponible en Kaggle, la cual contiene registros de incidentes de ciberseguridad reportados a nivel mundial entre los años 2015 y 2024. Se describe el contexto del problema, el análisis exploratorio de la base de datos, la estrategia de codificación e imputación de variables, el paradigma de aprendizaje propuesto y una revisión de cuatro artículos científicos relacionados con el problema abordado.

Index Terms—Ciberseguridad, Machine Learning, Clasificación Multiclase, Aprendizaje supervisado, Triage en tiempo real.

I. DESCRIPCIÓN DEL PROBLEMA

A. Contexto del problema y utilidad de Machine Learning

En el marco de la ciberseguridad industrial y organizacional moderna, los centros de operaciones de seguridad (SOC) y los equipos de respuesta ante incidentes (CSIRT) se enfrentan a un volumen masivo y heterogéneo de alertas digitales. Entre los años 2015 y 2024, la sofisticación y el impacto económico de los ciberataques contra sectores críticos —tales como finanzas, salud, energía, educación, gobierno y telecomunicaciones— han experimentado un crecimiento exponencial.

Las herramientas de seguridad tradicionales, fundamentadas en reglas estáticas e identificadores de firma predefinidos, resultan insuficientes para evaluar la gravedad de amenazas desconocidas o para estimar las pérdidas financieras en el momento en que se detecta la vulnerabilidad. La implementación de un sistema basado en *Machine Learning* brinda las siguientes capacidades operativas clave:

- Realizar un triaje automático en tiempo real ($t = 0$), categorizando la severidad de una alerta entrante (Low, Medium, High) tan pronto como se registra el incidente.
- Optimizar la asignación del personal analista hacia las amenazas de alto impacto, filtrando el ruido operativo de baja severidad.
- Estimar niveles de severidad y prioridad operacional para orientar decisiones estratégicas de mitigación en tiempo real.

B. Composición de la base de datos

El proyecto emplea la base de datos pública *Global Cybersecurity Threats (2015–2024)*, publicada por Atharva Soundankar en Kaggle [1]. La estructura de datos consta de:

- **Número de muestras (N):** 3 000 registros de incidentes de ciberseguridad a nivel global.
- **Número de variables (D):** 10 variables en la base de datos original. Durante el preprocesamiento, se construye 1 variable objetivo derivada (*Severity*), conformando un total de 11 variables en la arquitectura de datos:
 - 1) *Country* (categórica nominal): país de origen/destino del incidente (10 países).
 - 2) *Year* (cuantitativa discreta): año de ocurrencia del ataque (2015–2024).
 - 3) *Attack Type* (categórica nominal): tipo de ciberataque (DDoS, Phishing, SQL Injection, Ransomware, Malware, Man-in-the-Middle).
 - 4) *Target Industry* (categórica nominal): sector industrial afectado (IT, Banking, Healthcare, Retail, Education, Telecommunications, Government).
 - 5) *Financial Loss (in Million \$)* (cuantitativa continua): pérdida económica estimada en millones de USD.
 - 6) *Number of Affected Users* (cuantitativa discreta): cantidad total de registros o usuarios comprometidos por la brecha.
 - 7) *Attack Source* (categórica nominal): origen del atacante (Nation-state, Unknown, Insider, Hacker Group).
 - 8) *Security Vulnerability Type* (categórica nominal): tipo de vulnerabilidad explotada (Zero-day, Social Engineering, Unpatched Software, Weak Passwords).
 - 9) *Defense Mechanism Used* (categórica nominal): mecanismo de defensa desplegado (Antivirus, VPN, Encryption, Firewall, AI-based Detection).
 - 10) *Incident Resolution Time (in Hours)* (cuantitativa continua): tiempo, en horas, requerido para resolver completamente el incidente.
 - 11) *Severity* (categórica nominal): severidad de la amenaza entrante (Low, Medium, High).

C. Análisis exploratorio de datos (EDA)

Se realizó un análisis exploratorio de datos exhaustivo en el cuaderno Jupyter `EDA_Cybersecurity_Threats.ipynb`. La Tabla I resume los estadísticos descriptivos del conjunto de datos.

Cuadro I
ESTADÍSTICOS DESCRIPTIVOS DE LAS VARIABLES NUMÉRICAS
($N = 3\,000$).

Variable	Media	DE	Mín.	Mediana	Máx.
Financial Loss (M\$)	50.49	28.79	0.50	50.80	99.99
Affected Users	504 684	289 944	424	504 513	999 635
Resolution Time (h)	36.48	20.57	1.00	37.00	72.00
Year	2019.57	2.86	2015	2020	2024

Diagnóstico de Calidad y Relaciones: La inspección de calidad confirmó exactamente un **0% de valores faltantes** y **0 filas duplicadas** en las 3 000 muestras. La matriz de correlación entre variables numéricas no reveló relaciones lineales dominantes ($|r| < 0.05$), lo que demuestra que el nivel de severidad depende de interacciones complejas entre características categóricas (tipo de ataque, vulnerabilidad y sector afectado) y respalda el uso de modelos capaces de capturar interacciones no lineales entre variables.

Estrategia de Imputación y Codificación: Aunque el dataset original no requiere imputación, se establece como salvaguarda la imputación por la mediana para variables numéricas y por la moda para categóricas. La transformación de variables comprende:

- **One-Hot Encoding con `drop='first'`** en las 6 variables categóricas nominales para evitar la trampa de la variable ficticia (*dummy variable trap*).
- **Estandarización Z-score (`StandardScaler`)** sobre variables cuantitativas, calculando la media y desviación estándar exclusivamente sobre el conjunto de entrenamiento.

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

D. Paradigma de aprendizaje y justificación

Se adopta un paradigma de **aprendizaje supervisado enfocado en clasificación multiclase**.

- **Formulación de la Variable Objetivo (Severidad):** Se define la variable de severidad $Y \in \{\text{Low, Medium, High}\}$, discretizando mediante terciles un índice de impacto combinado *Impact Score*, calculado como el promedio del rango percentil de *Financial Loss* y de *Incident Resolution Time*. Esto genera 3 clases equitativamente balanceadas (1 000 muestras por clase).
- **Prevención de Data Leakage (Fuga de Datos):** Para dar cumplimiento estricto al objetivo operacional de triaje en tiempo real ($t = 0$), las variables *Financial Loss*, *Incident Resolution Time* e *Impact Score* se eliminan formalmente del espacio de características de entrada X . Dado que las pérdidas monetarias y las horas de resolución son métricas *post-hoc* (solo conocidas tras la investigación del incidente), su inclusión en X contaminaría el modelo con información del futuro. En consecuencia, la matriz X se restringe a las **8 variables antecedente** (características 1 a 4 y 6 a 9).

II. ESTADO DEL ARTE

Se revisaron cuatro artículos publicados en revistas e índices internacionales (IEEE, Springer y Elsevier/Scopus) sobre

clasificación de severidad e impacto de ciberamenazas mediante ML.

Artículo 1 [2] (*PriMera Scientific Engineering*, 2025) usa exactamente el mismo dataset de Kaggle. Paradigma híbrido: *K-Means* ($K=3$) para severidad y cuatro regresores (*Random Forest*, *Gradient Boosting*, SVR, Lineal) para pérdida financiera, validados con partición 80/20. Solo la Regresión Lineal logró $R^2 > 0$ (0.0009); los modelos no lineales sobreajustaron ($R^2 < 0$). El *clustering* alcanzó un *Silhouette Score* de 0.74, definido como $S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$.

Artículo 2 [3] (IJAIN, 2026) aborda clasificación multiclase supervisada de severidad con SVM, *Random Forest*, KNN y Naive Bayes, combinados con SMOTE y *SelectKBest*, validados con 10-Fold CV. El clasificador SVM con SMOTE y *SelectKBest* obtuvo 97.30% de exactitud (Accuracy, Precision, Recall y F1 estándar).

Artículo 3 [4] (*IEEE Access*, vol. 12, 2024) propone *Deep Learning* supervisado: un ensemble ponderado de CNN con auto-atención (*Self-Attention*), validado con partición 80/20. Alcanzó 98.69% de exactitud y 98.71% de precisión en clasificación binaria de tráfico DDoS vs. benigno.

Artículo 4 [5] (Springer Nature/PMC, 2025) implementa un framework híbrido supervisado XGBoost + SVM con *Grid Search*, validado con 10-Fold CV estratificado. Obtuvo 98.7% de exactitud y ROC-AUC de 0.991, donde $AUC = \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$.

Conclusión de la revisión: los trabajos evidencian que SVM, los ensambles (XGBoost) y las CNN con atención logran exactitudes consistentemente altas (97.30%–98.7%) en clasificación, mientras que la predicción continua de pérdidas financieras presenta alta varianza. Esto respalda el paradigma supervisado, combinando ensambles y clasificación multiclase como línea base del proyecto.

III. REPOSITORIO DE GITHUB

El proyecto se encuentra alojado en el repositorio público de GitHub:

https://github.com/acenerumination/MLProject_Cybersecurity_Threat_Severity_and_Impact_Classification

El repositorio contiene el archivo `README.md` con los pasos para reproducir los resultados reportados en este informe, además del cuaderno de Jupyter de análisis exploratorio (`EDA_Cybersecurity_Threats.ipynb`) en donde dichos resultados se desarrollan.

REFERENCES

- [1] A. Soundankar, "Global Cybersecurity Threats (2015–2024)," Kaggle Dataset. [Online]. Available: <https://www.kaggle.com/datasets/atharvasoundankar/global-cybersecurity-threats-2015-2024>
- [2] G. N. Ogochukwu, E. C. Henry, V. Palama, E. E. Akpan, *et al.*, "Integrating Artificial Intelligence with Cyber Threat Intelligence to Predict Financial Exposure in Data-Driven Enterprises," *PriMera Scientific Engineering*, vol. 7, 2025.
- [3] I. Riadi, S. Winiarti, H. Yuliansyah, and M. A. Bin Mohamad, "Machine Learning Model for Classifying the Severity Level of Cybersecurity Attacks," *International Journal of Advances in Intelligent Informatics (IJAIN)*, 2026.

- [4] S. Venkatraman, S. Kanthimathi, K. S. Jayasankar, T. P. Jiljith, and R. Jashwanth, "A Novel Self-Attention-Enabled Weighted Ensemble-Based Convolutional Neural Network Framework for Distributed Denial of Service Attack Classification," *IEEE Access*, vol. 12, pp. 151515–151531, 2024.
- [5] S. Palanisamy and M. Gopinath, "A Hybrid XGBoost–SVM Ensemble Framework for Robust Cyber-Attack Detection in the Internet of Medical Things (IoMT)," *PMC / Springer Nature*, 2025.