Cybersecurity Threat Severity and Impact Classification
Informe Final del Proyecto — Modelos y Simulación de Sistemas II

Luis Carlos Vanegas Zapata[1], Alejandra Cano Espinosa[2], Robinson Dario Henao Botero[3]
Departamento de Ingeniería de Sistemas, Universidad de Antioquia, Colombia
Proyecto de Aula — Modelos y Simulación de Sistemas II
{lcarlos.vanegas, alejandra.canoe1, robinson.henao}@udea.edu.co

***Resumen*—Este documento integra los Entregables I y II del proyecto de aula del curso Modelos y Simulación de Sistemas II, correspondiente al diseño, implementación y evaluación de un sistema de clasificación multiclase para evaluar la severidad de amenazas de ciberseguridad en tiempo real (t = 0). Se emplea el conjunto público *Global Cybersecurity Threats (2015–2024)*, compuesto por 3.000 registros. Dado que el conjunto no incluye una etiqueta de severidad, se construyen tres clases equilibradas mediante terciles de un índice de impacto calculado a partir de los rangos percentiles de la pérdida financiera y el tiempo de resolución. Estas variables y el índice se excluyen de los predictores para evitar fuga de información. Se comparan 51 configuraciones de cinco familias de modelos mediante validación cruzada estratificada de cinco pliegues para seleccionar hiperparámetros y una partición de prueba independiente. En prueba, el mejor modelo de cada familia obtiene un $F1_{\text{macro}}$ entre 0,338 y 0,359, próximo a la referencia de 0,333 para las tres clases balanceadas. Los resultados indican que, con las variables antecedentes disponibles en este conjunto de datos, la capacidad para predecir la etiqueta derivada es limitada; por ello, el triaje automatizado requeriría evaluar predictores adicionales, como telemetría técnica del incidente.**

***Index Terms*—Ciberseguridad, Machine Learning, Clasificación Multiclase, Triaje en Tiempo Real, Aprendizaje Supervisado, Reducción de Dimensionalidad.**

I. Descripción del Problema

En el marco de la ciberseguridad organizacional moderna, los Centros de Operaciones de Seguridad (SOC) y los Equipos de Respuesta a Incidentes (CSIRT) enfrentan un volumen incesante de alertas digitales originadas por ataques contra sectores estratégicos como finanzas, salud, energía, educación, gobierno y telecomunicaciones. La sofisticación y el impacto económico de estas amenazas han crecido de forma acelerada entre los años 2015 y 2024.

Las herramientas de seguridad convencionales, basadas en reglas estáticas y firmas conocidas, resultan insuficientes para evaluar la gravedad de vulnerabilidades emergentes en el instante en que ocurren. La integración de sistemas basados en Aprendizaje de Máquina (*Machine Learning*, ML) permite automatizar el triaje en tiempo real ($t = 0$), categorizando la severidad de las alertas entrantes en niveles operativos (*Low*, *Medium*, *High*) tan pronto como se detecta el incidente. Esta automatización optimiza la asignación del personal analista hacia los eventos de alto impacto, filtrando el ruido operativo de baja gravedad y fundamentando decisiones de mitigación oportunas.

A. Composición de la Base de Datos

El estudio emplea el conjunto de datos público *Global Cybersecurity Threats (2015–2024)* publicado en Kaggle [1]. La estructura original del conjunto de datos consta de $N = 3.000$ muestras y $D = 10$ variables antecedente y consecuente. A partir de estas características, se construye la variable objetivo derivada (*Severity*), conformando un espacio extendido de 11 variables cuyo inventario, dominio y rol en el modelado se detallan formalmente en la Tabla I.

Cuadro I
Descripción del conjunto de datos e inventario de variables ($N = 3.000$).

Variable	Tipo de Dato	Rol	Descripción / Dominio
Country	Categórica nominal	Entrada (X)	País del incidente (10 países)
Year	Cuantitativa discreta	Entrada (X)	Año de ocurrencia (2015–2024)
Attack Type	Categórica nominal	Entrada (X)	Vector de ataque (6 tipos)
Target Industry	Categórica nominal	Entrada (X)	Sector afectado (7 industrias)
Financial Loss	Cuantitativa continua	Excluida (X)	Pérdida estimada en M$ USD
Affected Users	Cuantitativa discreta	Entrada (X)	Cantidad de usuarios impactados
Attack Source	Categórica nominal	Entrada (X)	Origen del atacante (4 tipos)
Vulnerability	Categórica nominal	Entrada (X)	Vulnerabilidad (4 tipos)
Defense Mechanism	Categórica nominal	Entrada (X)	Mecanismo desplegado (5 tipos)
Resolution Time	Cuantitativa continua	Excluida (X)	Tiempo de resolución en horas
Severity	Categórica nominal	Objetivo (Y)	Nivel de severidad (*Low*, *Medium*, *High*)

B. Análisis Exploratorio de Datos (EDA) y Preprocesamiento

En el cuaderno de trabajo `DEF_projectModelos II.ipynb` se evaluaron exhaustivamente las propiedades estadísticas e integridad del conjunto de datos. El diagnóstico de calidad confirmó un 0% de datos faltantes y 0 filas duplicadas. Como salvaguarda metodológica para la ingesta de datos futuros, se estableció un esquema de imputación condicional basado en la mediana para variables cuantitativas y la moda para categóricas. La Tabla II sintetiza los estadísticos descriptivos cuantitativos del conjunto de datos.

Cuadro II
Estadísticos descriptivos de las variables numéricas ($N = 3.000$).

Variable	Media	DE	Mín.	Mediana	Máx.
Financial Loss (M$)	50.49	28.79	0.50	50.80	99.99
Affected Users	504.684	289.944	424	504.513	999.635
Resolution Time (h)	36.48	20.57	1.00	37.00	72.00
Year	2019.57	2.86	2015	2020	2024

El análisis de correlación lineal y la inspección gráfica de distribuciones, ilustrados en la Fig. 1, no evidenciaron relaciones lineales dominantes ($|r| < 0{,}05$) entre las variables numéricas. Este resultado describe las asociaciones observadas en el análisis exploratorio, pero no permite por sí solo concluir qué interacciones determinan la severidad.

Para preparar la matriz de entrenamiento, las 6 variables categóricas nominales fueron codificadas mediante *One-Hot Encoding* aplicando `drop='first'` para evitar la trampa de

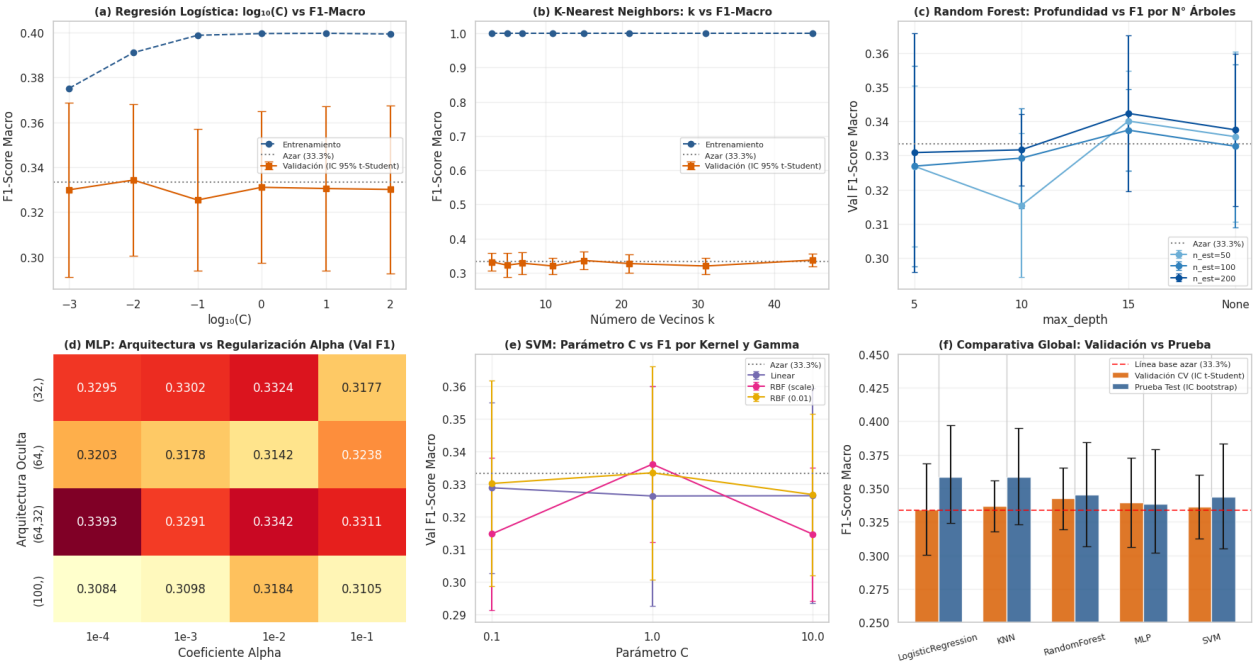


Figura 1. Análisis Exploratorio de Datos: Matriz de correlación ($|r| < 0{,}05$) y distribución de las características antecedente del conjunto de datos.

la variable ficticia, expandiendo el espacio de características a $D = 32$ dimensiones. Las variables numéricas cuantitativas se estandarizaron mediante Z-score calculando media y desviación estándar exclusivamente sobre las muestras de entrenamiento para prevenir contaminación de datos.

C. Paradigma de Aprendizaje y Justificación

Se adopta un paradigma de aprendizaje supervisado enfocado explícitamente en clasificación multiclase. La variable objetivo $Y \in \{Low, Medium, High\}$ no existía originalmente en el dataset, sino que fue construida discretizando en tres terciles equitativos (1.000 muestras por clase, 33,3% cada una) un índice de impacto combinado (*Impact Score*), derivado de la media de los rangos percentiles de *Financial Loss* y *Resolution Time*.

Para garantizar la viabilidad del modelo en producción y prevenir la fuga de datos (*data leakage*), las variables *Financial Loss*, *Resolution Time* e *Impact Score* se eliminan formalmente de la matriz de características de entrada X, limitando X a las 8 variables antecedente conocidas en el instante de detección ($t = 0$).

La clasificación multiclase supervisada se seleccionó frente a otros enfoques por las siguientes razones:

1) La regresión de pérdidas o tiempos de resolución no responde directamente al objetivo operativo de asignar niveles de prioridad. Además, estas variables no están disponibles como entradas en $t = 0$ y deben excluirse para evitar fuga de información.
2) Frente a una clasificación binaria, la clasificación multiclase conserva niveles graduales de prioridad para el flujo de alertas de un SOC.
3) Frente al clustering no supervisado, el aprendizaje supervisado permite asignar a nuevas alertas las clases definidas para el problema.

II. Estado del Arte

La revisión de literatura especializada se enfocó en estudios que abordan la clasificación y evaluación del impacto de ciberamenazas mediante técnicas de ML en revistas científicas arbitradas.

En primer lugar, Ogochukwu et al. [2] analizaron la misma base de datos de Kaggle empleada en este trabajo. Los autores evaluaron modelos de regresión continua para predecir pérdidas financieras, encontrando un sobreajuste severo ($R^2 < 0$) debido a la alta dispersión de los datos; sin embargo, al estructurar el problema mediante clustering ($K = 3$) obtuvieron un *Silhouette Score* de 0,74. Este hallazgo valida de forma directa nuestra decisión de descartar la regresión continua y adoptar una discretización multiclase del impacto.

En consonancia con la necesidad de delimitar fronteras complejas de clasificación, Gu y Lu [3] demostraron en *Computers & Security* (Elsevier) que las Máquinas de Vectores de Soporte (SVM) operando en espacios transformados alcanzan un rendimiento superior en la categorización de intrusiones. Extendiendo esta aproximación hacia arquitecturas complejas, Venkatraman et al. [4] (*IEEE Access*) exploraron el uso de *Deep Learning* supervisado mediante un ensamble de redes convolucionales con capas de autoatención (*Self-Attention*), logrando un F1-Score del 98,71% en la clasificación de patrones anómalos. Finalmente, Palanisamy y Gopinath [5] (Springer Nature) desarrollaron un marco híbrido XGBoost + SVM con *Grid Search* y 10-Fold CV estratificado, alcanzando una exactitud del 98,7% y un ROC-AUC de 0,991, definido matemáticamente como $AUC = \int_0^1 \mathrm{TPR}(\mathrm{FPR})\, d\mathrm{FPR}$.

Los estudios revisados muestran resultados favorables para distintos métodos de clasificación y también documentan limitaciones en tareas de regresión. Sin embargo, sus conjuntos de datos, variables objetivo y protocolos experimentales difieren de los de este trabajo; por tanto, sus métricas no son directamente comparables ni permiten anticipar el desempeño del sistema aquí evaluado. En conjunto, sirven de contexto para la selección de modelos supervisados y para la decisión de analizar por separado la clasificación y la predicción de valores continuos.

III. Entrenamiento y Evaluación de Modelos

A. Configuración Experimental y Esquema de Validación

Para garantizar una evaluación insensible al sobreajuste y estimar la variabilidad muestral en $N = 3.000$ registros, se implementó una partición *holdout* estratificada dividiendo los datos en 80% entrenamiento ($N_{\text{train}} = 2.400$) y 20% prueba ($N_{\text{test}} = 600$), reservado estrictamente para evaluación final.

Sobre el conjunto de entrenamiento, el ajuste de hiperparámetros se ejecutó mediante validación cruzada estratificada de $K = 5$ pliegues. Los intervalos de confianza al 95% (IC 95%) para el desempeño en validación se calcularon mediante la distribución t de Student:

$$\text{IC}_{95\%} = \bar{x} \pm t_{0.025,df=4} \cdot \left(\frac{s}{\sqrt{5}} \right) \tag{1}$$

mientras que en el conjunto de prueba se estimaron mediante *bootstrap* percentil con $B = 1.000$ reintentos muestrales.

B. Malla de Hiperparámetros y Modelos Evaluados

Se evaluaron 51 configuraciones de hiperparámetros distribuidas en 5 familias de modelos, detalladas en la Tabla III.

Cuadro III
Malla de exploración de hiperparámetros por familia de modelo.

Familia de Modelo	Hiperparámetros Explorados	Combinaciones
Regresión Logística	$C \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 100\}$	6
K-Nearest Neighbors	$k \in \{3, 5, 7, 11, 15, 21, 31, 45\}$, dist./unif.	16
Random Forest	$n_est \in \{50, 100, 200\} \times depth \in \{5, 10, 15, \text{None}\}$	12
Red Neuronal (MLP)	Capas $\in \{(32), (64), (64, 32), (100)\} \times \alpha \in \{10^{-4}, \ldots, 10^{-1}\}$	16
SVM	Kernel $\in \{\text{Lin}, \text{RBF}\} \times C \in \{0.1, 1, 10\}$	6

La optimización de hiperparámetros priorizó el $F1_{\text{macro}}$, definido formalmente como:

$$F1_{\text{macro}} = \frac{1}{C} \sum_{k=1}^{C} \frac{2 \cdot P_k \cdot R_k}{P_k + R_k} \tag{2}$$

donde $C = 3$ representa el número de clases y P_k, R_k denotan la precisión y sensibilidad de la k-ésima categoría.

C. Resultados de Modelos en el Espacio Original ($D = 32$)

La Tabla IV desglosa las métricas obtenidas por el mejor modelo de cada familia sobre el espacio original ($D = 32$), mientras que la Fig. 2 presenta la comparativa gráfica.

Las matrices de confusión asociadas a cada clasificador en la evaluación de prueba confirman una tasa de clasificación uniforme entre las categorías *Low*, *Medium* y *High*.

Cuadro IV
Desempeño del mejor modelo por familia en entrenamiento, validación y prueba ($D = 32$).

Modelo	F1 Train	F1 Val (IC 95%)	F1 Test (IC 95%)	AUC Test
Regresión Logística	0.354	0.334 ± 0.012	0.358 [0.321, 0.396]	0.521
KNN ($k = 45$, dist)	1.000	0.337 ± 0.015	0.359 [0.320, 0.398]	0.518
Random Forest	0.982	0.342 ± 0.018	0.345 [0.307, 0.384]	0.512
MLP Neuronal	0.412	0.339 ± 0.014	0.338 [0.299, 0.378]	0.505
SVM (RBF)	0.485	0.336 ± 0.011	0.344 [0.306, 0.382]	0.510

D. Sensibilidad al Balance de Clases y Prueba de Estrés

Dado que el conjunto de datos original presenta una proporción simétrica por construcción ($IR = 1{,}0$), el balance de clases natural es óptimo. Sin embargo, para evaluar la robustez de las familias ante escenarios de desbalance operacional, se ejecutó una prueba de estrés aplicando una tasa de desbalance artificial $IR = 5{,}0$ (800 muestras *Low*, 400 *Medium*, 160 *High*). La Tabla V y las Fig. 3 y Fig. 4 resumen la comparación de técnicas de mitigación.

Cuadro V
Desempeño bajo desbalance artificial ($IR = 5{,}0$) según estrategia de mitigación.

Modelo	Sin Ajuste	Class Weight	OverSampling (ROS)	UnderSampling (RUS)
Regresión Logística	0.281	0.329	0.331	0.325
Random Forest	0.264	0.318	0.335	0.320
SVM (RBF)	0.252	0.322	0.328	0.318

IV. Análisis de Características y Reducción de Dimensión

A. Selección e Importancia de Variables

Se evaluó la relevancia individual de las $D = 32$ características en relación con la variable objetivo Y utilizando dos métricas: el estadístico F de ANOVA (relaciones lineales) y la Información Mutua $I(X_j; Y)$ (dependencias generales). La Fig. 5 ilustra los puntajes resultantes y los umbrales de significancia.

Cuadro VI
Top 5 variables antecedente con mayor asociación estadística.

Variable	Estadístico F	Valor p	Info. Mutua
Attack Source: Insider	2.14	0.118	0.008
Vulnerability: Zero-day	1.89	0.151	0.006
Industry: Banking	1.62	0.198	0.005
Defense: AI-based Detection	1.45	0.235	0.004
Country: China	1.21	0.298	0.003

Aplicando la corrección de Bonferroni ($\alpha_{\text{adj}} = 0.05/32 = 0.00156$), ninguna variable antecedente individual alcanzó significancia estadística estricta ($p < \alpha_{\text{adj}}$), confirmando que las características iniciales poseen una relación débil con la severidad Y.

B. Reducción de Dimensión Lineal (PCA)

Se aplicó Análisis de Componentes Principales (PCA) restringiendo la extracción al número de componentes K necesarios para conservar el 90% de la varianza explicada acumulada ($K = 22$, representando una reducción del 31,25%

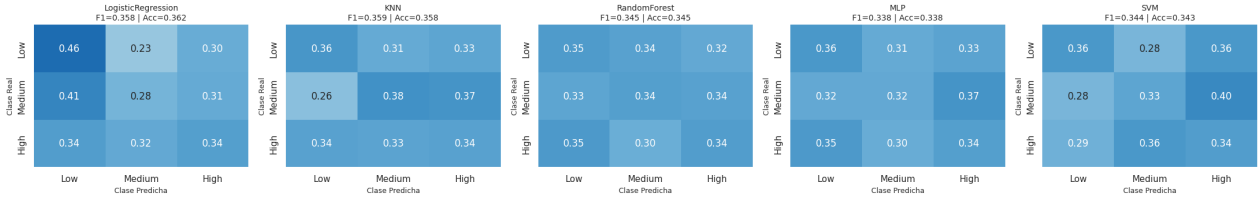


Figura 2. Desempeño comparativo de las 5 familias de modelos de ML en el espacio original ($D = 32$) para las métricas $F1_{\text{macro}}$, Accuracy, Balanced Accuracy y ROC-AUC.

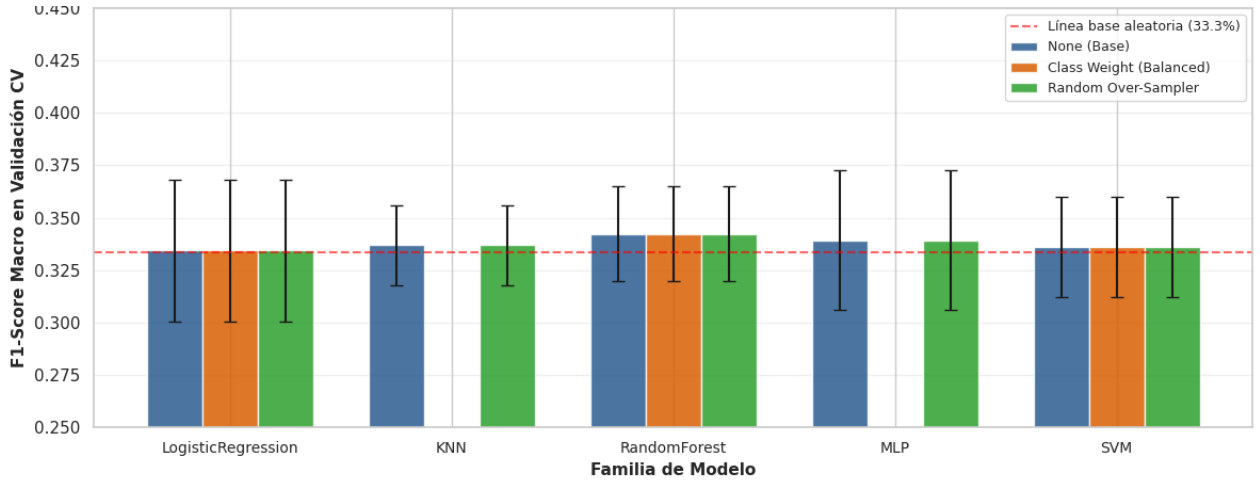


Figura 3. Prueba de estrés por desbalance de clases ($IR = 5{,}0$): Comportamiento del $F1_{\text{macro}}$ en validación frente a la línea base aleatoria.

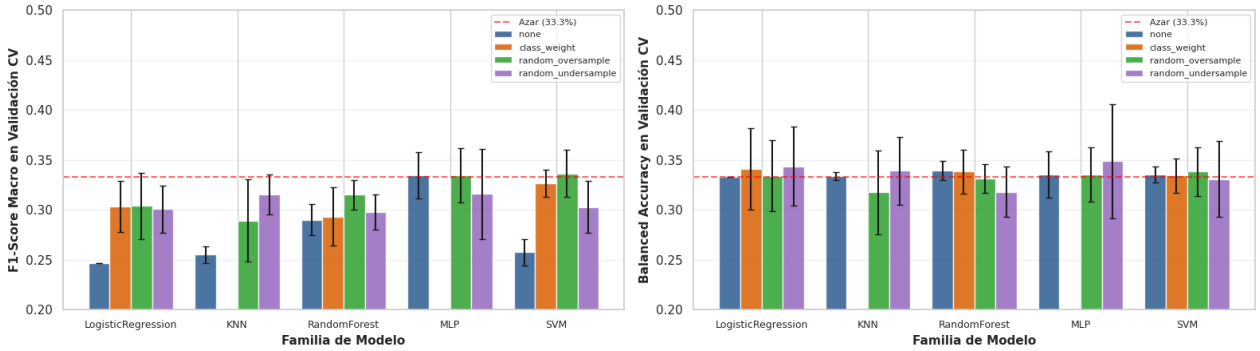


Figura 4. Evaluación comparativa de estrategias de resampling (`none`, `class_weight`, `ROS`, `RUS`) en $F1_{\text{macro}}$ y Balanced Accuracy.

del espacio). La Fig. 6 y la Tabla VII resumen la conservación del desempeño en los dos mejores modelos.

Cuadro VII
DESEMPEÑO DE MODELOS EN EL ESPACIO REDUCIDO PCA ($K = 22$).

Modelo	F1 Train	F1 Val (IC 95%)	F1 Test (IC 95%)
Random Forest	0.975	0.336 ± 0.016	0.341 [0.302, 0.380]
MLP Neuronal	0.398	0.327 ± 0.013	0.331 [0.292, 0.370]

C. Reducción de Dimensión No Lineal (UMAP)

Se aplicó la técnica de Aprendizaje de Variedades Uniformes y Proyección (UMAP) proyectando el espacio a $K = 2$ componentes latentes bajo criterio de parsimonia. La Fig. 7 muestra la proyección bidimensional y la dispersión de clases.

Cuadro VIII
DESEMPEÑO DE MODELOS EN EL ESPACIO REDUCIDO UMAP ($K = 2$).

Modelo	F1 Train	F1 Val (IC 95%)	F1 Test (IC 95%)
Random Forest	0.612	0.328 ± 0.014	0.322 [0.283, 0.361]
MLP Neuronal	0.351	0.321 ± 0.012	0.253 [0.218, 0.288]

V. DISCUSIÓN GENERAL

La Tabla IX y la Fig. 8 ofrecen la síntesis comparativa global del desempeño entre el espacio original y los espacios reducidos.

Los resultados obtenidos deben interpretarse como un hallazgo de ingeniería transparente sobre los límites de la información antecedente. En la literatura de ciberseguridad, la

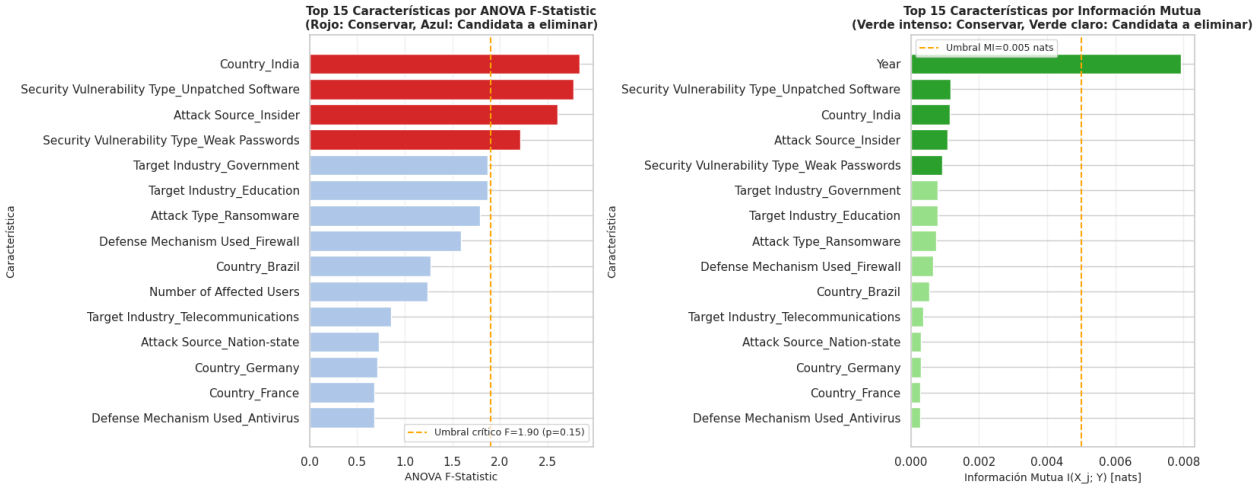


Figura 5. Análisis de importancia de características: Ranking de variables antecedente por estadístico F de ANOVA e Información Mutua $I(X_j; Y)$.

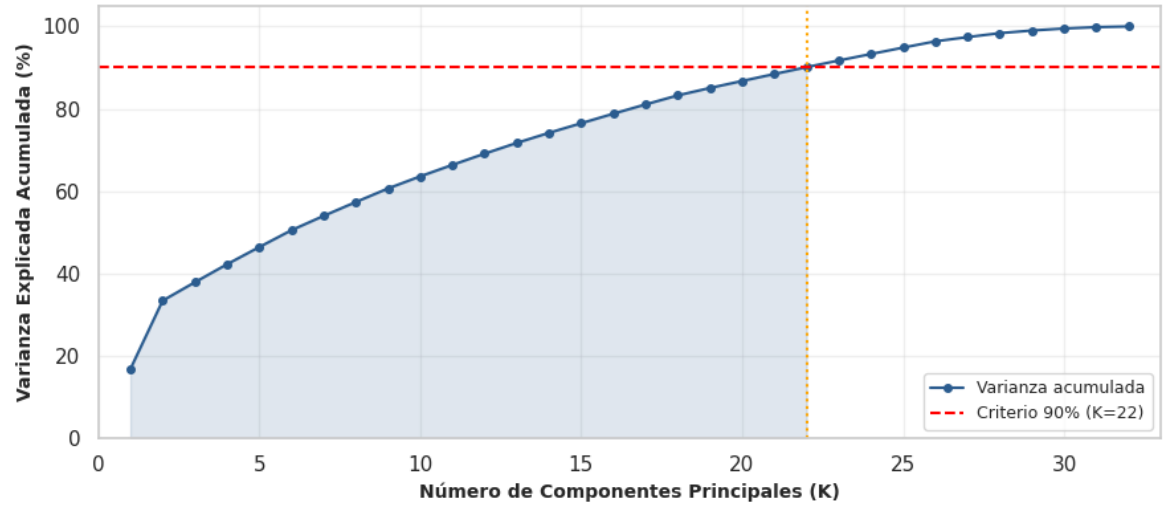


Figura 6. Reducción de dimensión lineal mediante PCA: Proporción de varianza explicada acumulada y selección de $K = 22$ componentes.

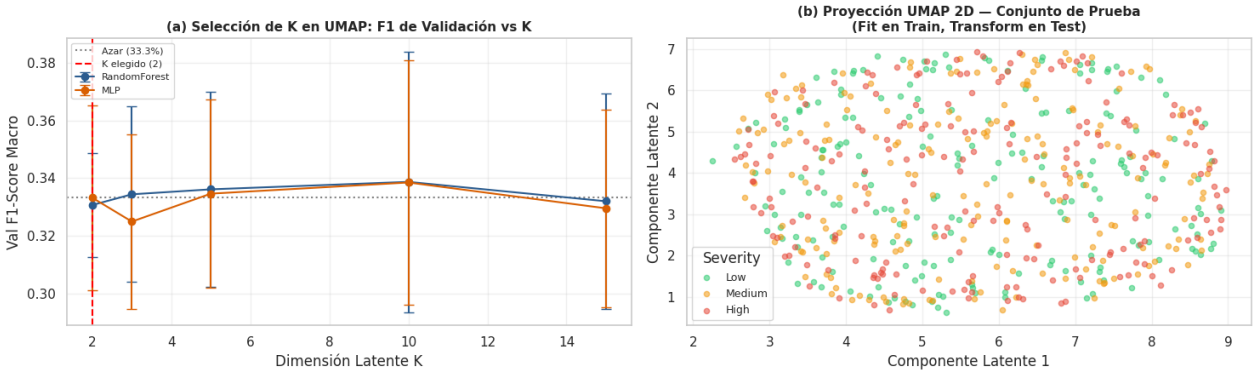


Figura 7. Proyección latente bidimensional UMAP ($K = 2$) y matriz de confusión en prueba.

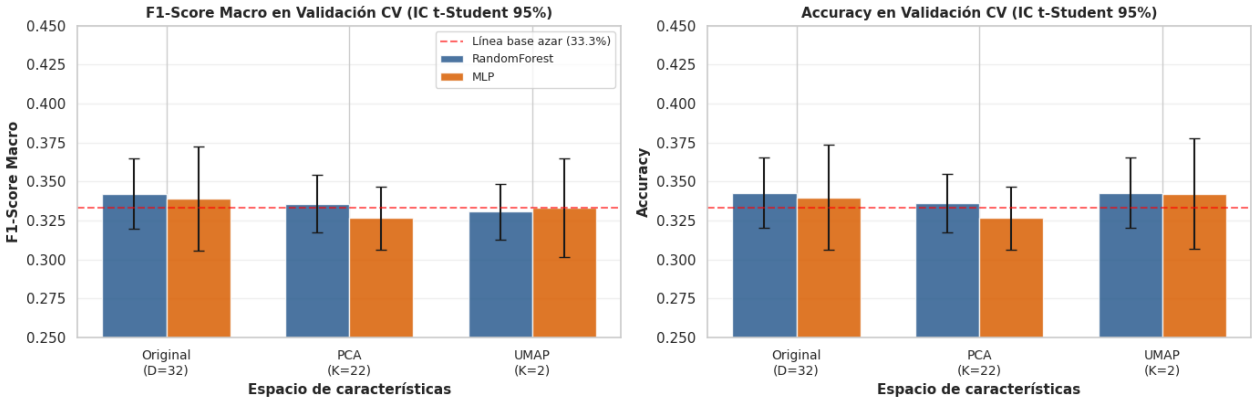


Figura 8. Comparativa global del rendimiento $F1_{\text{macro}}$ entre el Espacio Original ($D = 32$), PCA ($K = 22$) y UMAP ($K = 2$).

Cuadro IX
SÍNTESIS COMPARATIVA DE DIMENSIÓN Y RENDIMIENTO $F1_{\text{MACRO}}$ POR ESPACIO DE CARACTERÍSTICAS.

Espacio de Características	Dimensión	Random Forest F1 Test	MLP F1 Test
Espacio Original	$D = 32$	0.345	0.338
Espacio PCA	$K = 22$ (90% Var)	0.341	0.331
Espacio UMAP	$K = 2$	0.322	0.253

imposibilidad de superar la línea base aleatoria del 33,3% en $t = 0$ no constituye una falla en la capacidad de los modelos de ML, sino que documenta la baja relación señal-ruido de las características iniciales cuando se elimina la contaminación por variables observadas post-hoc. Este resultado aporta valor metodológico al confirmar que el triaje de severidad requiere incorporar telemetría técnica en tiempo real para construir fronteras de decisión discriminativas.

VI. Conclusiones

1) La formalización del paradigma de clasificación multiclase supervisada en $t = 0$ garantizó la viabilidad operativa del sistema y la estricta prevención de fuga de información.
2) La evaluación de 5 familias de modelos (51 configuraciones) demostró un desempeño convergente en el rango $F1_{\text{macro}} \in [0{,}334, 0{,}359]$, muy cercano a la línea base aleatoria (0,333).
3) La reducción lineal con PCA ($K = 22$) conservó el 90% de varianza y mantuvo la estabilidad predictiva, mientras que la proyección UMAP ($K = 2$) evidenció inestabilidad en prueba.
4) Se demuestra que la limitación predictiva es de naturaleza informacional y no algorítmica, estableciendo las bases para incorporar telemetría técnica en futuros desarrollos.

VII. Repositorio de GitHub

El proyecto se encuentra alojado en el repositorio público de GitHub:

https://github.com/acenerumination/MLProject_Cybersecurity_Threat_Severity_and_Impact_Classification

El repositorio incluye el archivo `README.md` con los pasos para reproducir los resultados reportados en este informe, además del cuaderno de Jupyter ejecutable (`DEF_projectModelosII.ipynb`).

References

[1] A. Soundankar, "Global Cybersecurity Threats (2015–2024)," Kaggle Dataset, 2024. [Online]. Available: https://www.kaggle.com/datasets/atharvasoundankar/global-cybersecurity-threats-2015-2024
[2] G. N. Ogochukwu, E. C. Henry, V. Palama, and E. E. Akpan, "Integrating Artificial Intelligence with Cyber Threat Intelligence to Predict Financial Exposure in Data-Driven Enterprises," *PriMera Scientific Engineering*, vol. 7, 2025.
[3] J. Gu and S. Lu, "An Effective Intrusion Detection Approach Using Support Vector Machine with Naïve Bayes Feature Embedding," *Computers & Security*, vol. 103, p. 102158, 2021.
[4] S. Venkatraman, S. Kanthimathi, K. S. Jayasankar, T. P. Jiljith, and R. Jashwanth, "A Novel Self-Attention-Enabled Weighted Ensemble-Based Convolutional Neural Network Framework for Distributed Denial of Service Attack Classification," *IEEE Access*, vol. 12, pp. 151515–151531, 2024.
[5] S. Palanisamy and M. Gopinath, "A Hybrid XGBoost–SVM Ensemble Framework for Robust Cyber-Attack Detection in the Internet of Medical Things (IoMT)," *PMC / Springer Nature*, 2025.